HACKPERTUS · ARCHIVES

# ArchAI

Deciphering Swiss Archives with Apertus: Making Swiss archives answerable using Apertus model family

# Challenge

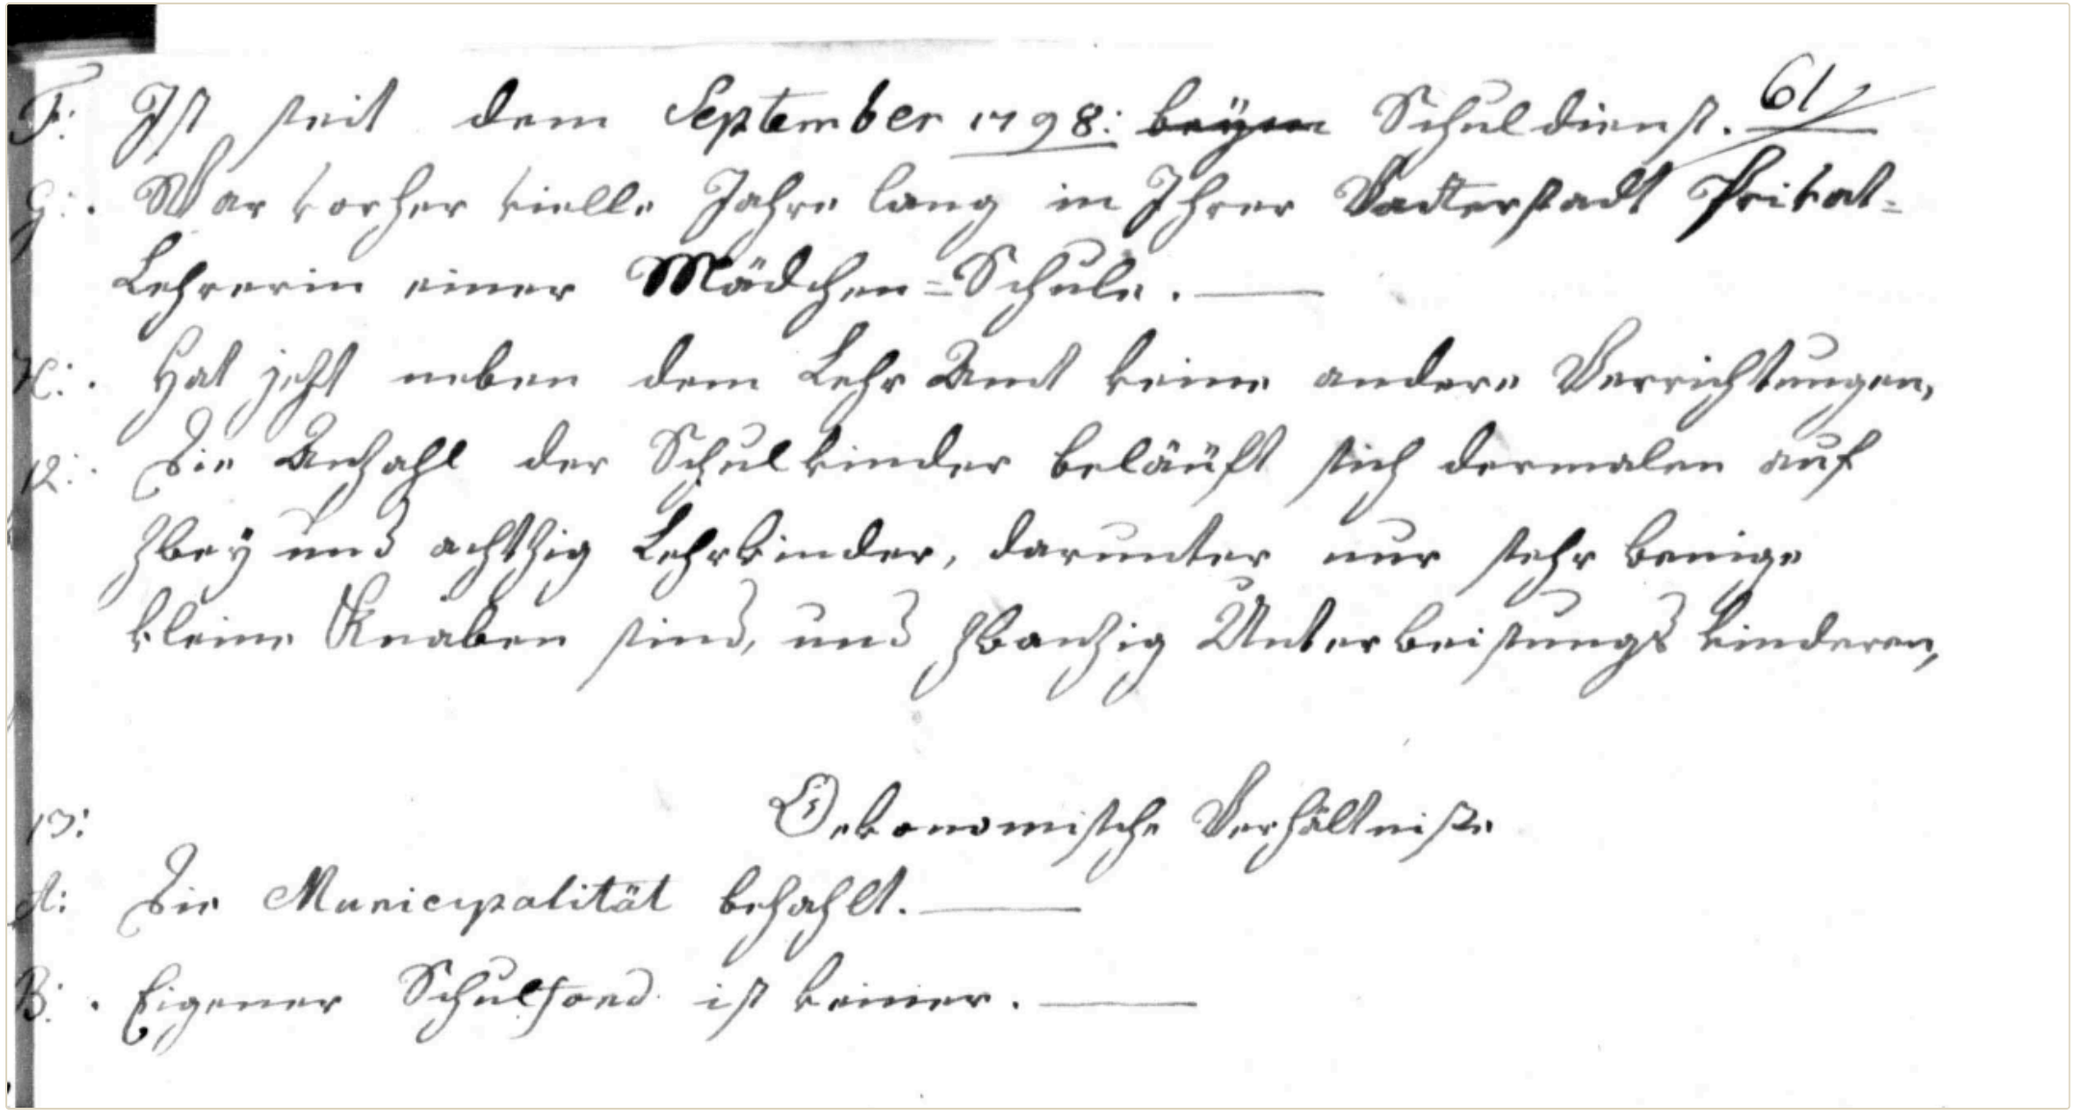
How can we make archives easily searchable?

## SUCHERGEBNISSE FÜR "BERN"

| Schulort | Gemeinde 2000 | Kirchgemeinde 1799 | Kanton 2000 | Kanton 1799 | Ort/Herrschaft 1750 |
|---|---|---|---|---|---|
| ▸ Au | Au | **Bern**eck | St. Gallen | Säntis | Gemeine Herrschaft Rheintal |
| ▾ **Bern** (9 Transkriptionen)<br>Transkription Nr 1077<br>• Bern, Aarbergergasse (Niedere Schule, reformiert)<br>Transkription Nr 1078<br>• Bern, Brunngasse (Niedere Schule, reformiert)<br>Transkription Nr 1079<br>• Bern, Mittleres Stadtquartier (Niedere Schule, Knabenschule, reformiert)<br>Transkription Nr 1080 | **Bern** | **Bern**, Heiliggeistkirche, **Bern**, Münster, **Bern**, Mittleres Stadtquartier, **Bern**, Nydeggkirche, **Bern**, Französische Kirche | Bern | Bern | Bern |

| | | |
|---|---|---|
| III.11.e | Hat er Familie? Wie viele Kinder? | Hat Kinder zwey Mädchen. |
| III.11.f | Wie lang ist er Schullehrer? | ll[Seite 3] Jst seit dem *September* 1798: ~~beym~~ Schuldienst. |
| III.11.g | Wo ist er vorher gewesen? Was hatte er vorher für einen Beruf? | War vorher vielle Jahre lang in Jhrer Vatterstadt PrivatLehrerin einer Mädchen-Schule. |
| III.11.h | Hat er jetzt noch neben dem Lehramte andere Verrichtungen? Welche? | Hat jezt neben dem Lehr Amt keine andere Verrichtungen, |
| III.12 | Schulkinder. Wie viele Kinder besuchen überhaupt die Schule? | Die Anzahl der Schulkinder beläuft sich dermalen auf zwey und achtzig Lehrkinder, darunter nur sehr wenige kleine Knaben sind, und zwanzig Unterweisungs kinderen, |
| III.12.a | Im Winter. (Knaben/ Mädchen) | |
| III.12.b | Im Sommer. (Knaben/ Mädchen) | |
| **IV. Ökonomische Verhältnisse.** | | |
| IV.13 | Schulfonds (Schulstiftung) | |
| IV.13.a | Ist dergleichen vorhanden? | Die *Municipalität* bezahlt. |
| IV.13.b | Wie stark ist er? | Eigener Schulfond ist keiner. |
| IV.13.c | Woher fließen seine Einkünfte? | |
| IV.13.d | Ist er etwa mit dem Kirchen- oder Armengut vereinigt? | |
| IV.14 | Schulgeld. Ist eines eingeführt? Welches? | Ehemals war von jedem Kind beym Eintritt in die Schule, oder Unterweisung, zehen Bazen zu forderen; Und alle angehende Winter fünf bazen Holzgeld, und fünf bazen Kirchengeld, lezteres nur von Unterweisungs kinderen. Alles ist aber abgeschaft seit 1787· |

# The goal: archives that are easily digestible



F: Ist seit dem September 1798: ~~keine~~ Schuldienst. 61
G: War vorher viele Jahre lang in ihrer Vaterstadt Privat-
Lehrerin einer Mädchen-Schule. ——
H: Hat jetzt neben dem Lehr-Amt keine andere Verrichtungen,
I: Die Anzahl der Schulkinder beläuft sich dermalen auf
über und achtzig Lehrkinder, darunter nur sehr wenige
kleine Knaben sind, und ebenso viele Mädchen existiren hiesigen

J: Ökonomische Verhältnisse
K: Die Municipalität besoldet. ——
L: Eigener Schulfond ist keiner. ——

# Our product

# Provenance

Every record keeps where it came from: the source dataset and its licence, the source file with its SHA-256, the row number, the archive signature and the archive viewer URL.

- 100 % of the 2,250 transcriptions carry an archive signature; 2,248 also link their facsimile — linked on stapferenquete.ch, never copied.
- 857 of 858 archive references were matched into the archive database, by exact match.
- 0 of 2,819 exported records failed the schema; an invalid record is quarantined instead of exported.
- Against the University of Bern export: 100 % of 12,047 question answers matched on TransID and question, 99.8 % of texts ≥ 0.95 similar.

`data/out/metrics.json → stapfer, linking, export, bern_reference · docs/reference/outputs.mdx`

BUSINESS · NEXT

# Pipelining, onboarding more datasets, a new customer base

- Pipelining: idempotent, resumable stages and a run manifest with the hash of every output. The two Apertus stages are optional — without a key they are skipped and everything after them still runs.
- Onboarding more datasets: any tabular open-data file goes through acquire → profile → map → transform → privacy → validate. Apertus proposes the column mapping and code validates it; onboarding the 569-row consultations table this way reproduced the hand-built records.
- A new customer base: the same path makes another archive, library or research group searchable, without new pipeline code.

README.md (robustness) · docs/reference/onboarding.mdx, docs/reference/measured-results.mdx

BUSINESS · COST

# Cost: tokens and calls, not currency

| ARTIFACT | HOW IT IS SERVED | TOKENS AT QUERY TIME |
|---|---|---|
| Starlight documentation site (docs/) | static Astro build, built in CI | 0 |
| This deck | Astro + reveal.js, `SINGLE_FILE=1` → one HTML file that opens from disk | 0 |
| ArchAI Q&A | Python app, search index built at startup (10–25 s) | only with an Apertus key; 0 without |

- API cost of the enrichment run: 2,250 calls, one per sheet.
- Token cost of that run: 2,174,008 tokens (1,784,954 in, 389,054 out) — 966 tokens per sheet.
- One question: one validated rewrite call, plus one call to write the answer.
- No price per token is stated in this repository, and the gateway and model are configurable — so the honest unit here is tokens and calls, not currency.

`data/out/apertus_enrichment.apertus-v1-5-70b.jsonl (2,250 rows) · data/out/metrics.json · docs/reference/web-demo.mdx · docs/ (Starlight site)`